

深度学习导论实验 4：基于 SimCLR 的 AIGC 生成图像检测

赵文凯 PB23000209

1. 实验任务与数据集

本实验使用 CIFAKE 数据集做二分类，把 CIFAR-10 中的真实图像记为 `REAL`，把 Stable Diffusion 生成图像记为 `FAKE`。数据集采用 `ImageFolder` 目录结构，原始训练集包含 100000 张图像，测试集包含 20000 张图像。考虑到需要同时完成主实验和多组附加实验，本文使用 `sample_ratio=0.1`，即抽取 10% 数据参与训练和测试，满足题目“不少于总数据量 10%”的要求。

在本次设置下，训练划分如下：抽样后训练部分共 10000 张，其中 9000 张用于训练、1000 张用于验证；测试集抽样后为 2000 张。冻结线性评估时，1% 标注比例约使用 90 张带标签训练图像，10% 标注比例约使用 900 张带标签训练图像。

受训练时间限制，本文没有使用全量 CIFAKE，而是采用 10% 子集完成所有主实验和附加实验。为了减少子集实验的不稳定性，所有实验固定随机种子为 42，并保持相同的数据划分、batch size 和训练轮数。本文更关注不同方法之间的相对趋势，而不是追求最高绝对指标。

2. 方法

本实验使用 SimCLR 框架进行自监督表示学习。预训练阶段不使用类别标签，对同一张图像生成两个随机增强视图，并将它们作为正样本对；同一 batch 中其他图像的视图作为负样本。模型由 Encoder 和 Projection Head 两部分组成。Encoder 提取 128 维图像表示，Projection Head 将其映射到 64 维对比学习空间用于计算损失。下游评估阶段丢弃 Projection Head，冻结 Encoder，仅训练一个单层线性分类器完成 `FAKE / REAL` 二分类。

数据增强使用 torchvision 实现。强增强包含随机裁剪、水平翻转、随机旋转、颜色抖动、随机灰度化和高斯模糊；弱增强降低颜色抖动强度，取消高斯模糊，并降低灰度化概率。两种增强都保留 32x32 输入尺寸，并使用 CIFAR 风格均值与标准差归一化。

主要损失函数为手写实现的 NT-Xent。设一个 batch 中有 N 张原图，经过两路增强后得到 $2N$ 个投影向量。每个样本以另一路增强结果为正样本，以剩余 $2N-2$ 个向量为负样本，通过温度系数缩放余弦相似度并计算交叉熵损失。附加实验中还实现并比较了 Contrastive Loss 和 Triplet Loss。

3. 模型结构

本实验比较了 ResNet-18 和 MobileNetV2 两种轻量级 Encoder。ResNet-18 针对 32x32 图像进行了调整：第一层卷积改为 3x3、stride=1、padding=1，并移除原始 max pooling，以避免过早降低小尺寸图像的空间分辨率；最后全连接层输出 128 维特征。MobileNetV2 使用原始倒残差结构，将分类头替换为输出 128 维特征的线性层。

Projection Head 默认结构为 `Linear(128,128) -> ReLU -> Linear(128,64)`。附加实验还测试了加入 BatchNorm 的版本，以及隐藏层扩展为 256 维的 wide 版本。

4. 实验设置

配置项	取值
sample_ratio	0.1
batch_size	1024
pretrain_epochs	100
linear_epochs	50
optimizer	AdamW
learning_rate	0.002
weight_decay	0.0001
feature_dim	128
projection_dim	64
默认 temperature	0.5
默认 Projection Head	plain
默认数据增强	strong
随机种子	42

5. 主实验结果

主实验比较 SimCLR 预训练后冻结线性评估与随机初始化 baseline。指标为测试集 Accuracy 和 macro F1 Score。




Figure 1: 主实验 Accuracy 与 F1 对比

Encoder	评估方式	标注比例	Accuracy	F1 Score
ResNet-18	SimCLR + frozen linear	1%	0.7180	0.7159
ResNet-18	Baseline from scratch	1%	0.6900	0.6893
ResNet-18	SimCLR + frozen linear	10%	0.7560	0.7560
ResNet-18	Baseline from scratch	10%	0.8085	0.8052
MobileNetV2	SimCLR + frozen linear	1%	0.5820	0.5819
MobileNetV2	Baseline from scratch	1%	0.5190	0.3417
MobileNetV2	SimCLR + frozen linear	10%	0.6185	0.6178
MobileNetV2	Baseline from scratch	10%	0.5190	0.3417

从结果看，ResNet-18 在本实验设置下整体优于 MobileNetV2。对于 1% 标注数据，ResNet-18 的 SimCLR 冻结评估明显高于 baseline，Accuracy 从 0.6900 提升到 0.7180，这说明自监督预训练在极低标注比例下确实提供了额外信息；但在 10% 标注比例下，ResNet-18 baseline 反而更高，说明当标注样本增加后，端到端监督训练可以更直接地适配二分类目标。

MobileNetV2 的 baseline 结果明显异常，Accuracy 为 0.5190，macro F1 只有 0.3417，接近只预测单一类别的结果。由于 SimCLR 冻结评估下 MobileNetV2 能达到 0.6178 F1，数据本身并没有明显问题，更可能是当前端到端 baseline 的优化设置不适合 MobileNetV2。因此本文不把 MobileNetV2 baseline 作为模型优劣的唯一依据，后续分析主要参考 SimCLR 线性评估和 ResNet-18 的对比。




Figure 2: SimCLR 预训练 Loss 曲线

预训练损失曲线显示，ResNet-18 与 MobileNetV2 的 NT-Xent loss 都在前几十个 epoch 明显下降，后期趋于平稳，没有出现发散。ResNet-18 的最终预训练 loss 为 5.9408，MobileNetV2 为 6.2003；ResNet-18 下游线性评估表现也更好，二者趋势一致。




Figure 3: 线性评估验证集 F1 曲线

线性评估曲线进一步显示，ResNet-18 baseline 在 10% 标注数据下验证 F1 上升最快，最终也取得最高测试指标；MobileNetV2 baseline 长期停留在较低 F1，没有有效学到二分类边界，而 SimCLR 预训练能让 MobileNetV2 的线性评估结果更稳定。

6. 附加实验

附加实验均使用 ResNet-18，在 10% 标注比例下进行冻结线性评估。




Figure 4: 附加实验 Accuracy 与 F1 对比

6.1 不同 Loss 的影响

Loss	Pretrain best loss	Accuracy	F1 Score	结论
NT-Xent	5.9408	0.7560	0.7560	默认 SimCLR 损失, 整体优于替代 loss
Contrastive Loss	0.0546	0.6705	0.6703	表示质量明显下降
Triplet Loss	0.0070	0.6735	0.6727	略优于 Contrastive, 但仍低于 NT-Xent

NT-Xent 在本任务上效果最好。一个可能原因是 NT-Xent 显式利用 batch 内所有负样本进行归一化对比, 更适合 SimCLR 的大 batch 训练设定; 而 Triplet / Contrastive Loss 当前实现只构造了较有限的负样本关系, 监督信号较弱。

6.2 Projection Head 结构分析

Projection Head	Pretrain best loss	Accuracy	F1 Score	结论
plain	5.9408	0.7560	0.7560	默认两层 MLP
batchnorm	5.9042	0.7635	0.7635	优于 plain, Batch-Norm 改善投影空间稳定性

Projection Head	Pretrain best loss	Accuracy	F1 Score	结论
wide	5.9067	0.7650	0.7650	本组中最优，隐藏层容量增加带来小幅提升

Projection Head 结构会影响下游线性可分性。加入 BatchNorm 后 Accuracy 从 0.7560 提升到 0.7635，wide 版本进一步达到 0.7650。说明适当提高 Projection Head 的稳定性或容量，可以让 Encoder 学到更适合下游任务的表示，但提升幅度小于温度系数和增强策略的影响。

6.3 温度系数影响

Temperature	Pretrain best loss	Accuracy	F1 Score	结论
0.2	3.7032	0.7835	0.7833	最优，显著优于默认 0.5
0.5	5.9408	0.7560	0.7560	默认设置，表现稳定
1.0	6.7553	0.7540	0.7539	温度偏高，区分度下降

在本组实验里，温度系数的影响最明显。把 temperature 从 0.5 调到 0.2 后，Accuracy 从 0.7560 提升到 0.7835。较小温度会放大相似度差异，使模型更关注 hard negatives；温度为 1.0 时相似度分布更平滑，正负样本区分压力降低，最终指标低于 0.2。

6.4 数据增强强度影响

Augmentation	Pretrain best loss	Accuracy	F1 Score	结论
strong	5.9408	0.7560	0.7560	增强更丰富，但可能破坏部分判别细节
weak	5.8993	0.7695	0.7695	本任务下更优

弱增强在本实验中优于强增强。这也符合 CIFAKE 的特点：图像只有 32x32，真实图像与生成图像之间的差异可能体现在纹理、颜色统计和局部伪影上，过强的颜色扰动和模糊可能会把本来就很弱的伪影线索抹掉。

7. 讨论

本实验结果表明，SimCLR 可以在低标注比例下学习到有效的视觉表示，尤其在 ResNet-18 的 1% 标注设置下，预训练使 Accuracy 从 0.6900 提升到 0.7180；在 MobileNetV2 的 baseline 训练失败时，预训练表征也明显改善 F1 Score。但 SimCLR 并不总是优于端到端监督训练：在 ResNet-18、10% 标注比例下，baseline 达到 0.8085 Accuracy，高于默认 SimCLR 的 0.7560。这说明自监督预训练的收益与标注比例、模型结构、增强策略和下游训练方式有关。

从附加实验看，NT-Xent 是更适合 SimCLR 的损失函数，温度系数是影响最大的超参数之一，temperature=0.2 将 Accuracy 提升到 0.7835；Projection Head 使用 BatchNorm 或更宽隐藏层

也能带来小幅增益。对于 CIFAKE 这种小尺寸伪造图像检测任务，弱增强反而优于强增强，说明增强策略需要结合任务特征设计，而不是越强越好。

8. 总结

本实验完成了 SimCLR 的完整训练流程，包括双视图数据增强、Encoder + Projection Head 构建、NT-Xent 损失手写实现、冻结线性评估和 baseline 对比。实验结果显示，ResNet-18 是当前设置下更合适的 Encoder；默认 SimCLR 在 1% 标注比例下明显优于 baseline，但 10% 标注比例下不如端到端监督训练。附加实验中，temperature=0.2 获得最佳 SimCLR 下游结果，Accuracy 为 0.7835，F1 Score 为 0.7833；弱数据增强也取得了 0.7695 Accuracy，说明针对小尺寸 AIGC 检测任务保留局部判别细节很重要。